

RAPPORT DE STAGE

En vue de l'obtention du diplôme de
Licence Mathématiques
Parcours **Statistique et Applications**
Université de Poitiers
UFR Sciences Fondamentales et Appliquées

Réalisé par : Katr Nada Maatallah

Soutenu le : 01/06/2026

« Apprentissage statistique : théorie et applications
pour le modèle de régression linéaire »

Application à la prédiction du profit de startups

Dates du stage : du 01/05/2026 au 31/05/2026

Lieu du stage : Université de Poitiers – UFR SFA

Tuteur de stage : Yousri Slaoui

Enseignant-référent : Nicolas James

Année universitaire 2025/2026

Résumé :

Ce rapport présente une étude du modèle de régression linéaire dans le cadre de l'apprentissage statistique. L'objectif est d'expliquer les fondements théoriques du modèle, notamment la méthode des moindres carrés, puis de les appliquer à un problème de prédiction du profit de startups. À partir d'un jeu de données contenant des variables financières et géographiques, plusieurs étapes sont réalisées : exploration des données, prétraitement, modélisation, évaluation et comparaison de modèles.

Mots-clés : apprentissage statistique, régression linéaire, moindres carrés, prédiction, startups, profit, Python, pandas, scikit-learn, Jupyter Notebook.

Abstract :

This report studies the linear regression model in the context of statistical learning. The aim is to present the theoretical foundations of the model, especially the ordinary least squares method, and then apply them to a startup profit prediction problem. Using a dataset containing financial and geographical variables, several steps are carried out : data exploration, preprocessing, modelling, evaluation and model comparison.

Key words : statistical learning, linear regression, ordinary least squares, prediction, startups, profit, Python, pandas, scikit-learn, Jupyter Notebook.

Remerciements

Ce travail marque l'aboutissement de mon stage de fin d'année réalisé dans le cadre de la Licence Mathématiques, parcours Statistique et Applications, à l'Université de Poitiers. Il m'a permis d'approfondir mes connaissances en apprentissage statistique, en régression linéaire et en analyse de données, tout en mettant en pratique les notions étudiées au cours de ma formation.

Je tiens à exprimer ma profonde reconnaissance à mon encadrant académique, Monsieur Yousri Slaoui, pour son accompagnement, sa patience et sa disponibilité tout au long de ce travail. Ses conseils précieux, ses remarques constructives et son soutien m'ont permis d'avancer avec plus de confiance, de mieux structurer mon étude et d'améliorer la qualité de ce rapport. Je le remercie sincèrement pour son implication et pour l'attention qu'il a portée à mon travail durant toute l'année.

Je tiens également à exprimer ma reconnaissance à Monsieur Nicolas James, responsable de notre formation et enseignant, pour son investissement, sa disponibilité et la qualité de son accompagnement. Ses enseignements, ses conseils et son implication dans le parcours Licence Mathématiques, parcours Statistique et Applications, m'ont permis de consolider mes bases en mathématiques, en statistique, en probabilités et en modélisation.

J'adresse aussi mes remerciements à l'ensemble des enseignants de la Licence Mathématiques, parcours Statistique et Applications, pour la qualité des enseignements dispensés et pour les connaissances qu'ils m'ont transmises tout au long de mon parcours.

Ce stage a été pour moi une occasion importante de relier la théorie à la pratique, notamment à travers l'utilisation de Python, de Jupyter Notebook et de bibliothèques spécialisées telles que pandas, scikit-learn et statsmodels. Il m'a permis de mieux comprendre les étapes d'un projet d'apprentissage statistique, depuis l'exploration des données jusqu'à l'évaluation des modèles.

Enfin, j'adresse mes remerciements les plus sincères à ma famille et à mes proches pour leur soutien moral, leur patience et leurs encouragements constants. Leur présence m'a accompagnée tout au long de cette année et m'a permis de mener ce travail avec sérieux et détermination.

Table des matières

Introduction générale	1
Présentation de la structure d'accueil	2
Développement	3
1 Cadre théorique	4
2 Hypothèses et évaluation du modèle linéaire	4
3 Présentation et préparation du jeu de données	5
4 Exploration des données	6
5 Modélisation par régression linéaire	8
6 Analyse des résidus	9
7 Comparaison avec le modèle KNN Regressor	9
8 Discussion, limites et perspectives	10
Conclusion générale	12
Bibliographie	13
Annexes	14
Annexe A : Extraits du code Python	14
Annexe B : Résultats détaillés du modèle KNN	15
Annexe C : Figures complémentaires	16

Table des figures

1	Matrice de corrélation des variables numériques	7
2	Comparaison entre les profits réels et les profits prédits	8
3	Distribution des dépenses en recherche et développement	16
4	Distribution des dépenses administratives	17
5	Distribution des dépenses marketing	17
6	Distribution du profit	17
7	Boxplots des principales variables numériques	18
8	Relations entre les variables numériques du jeu de données	18
9	Boxplot de la variable Profit	19
10	Évolution de la RMSE du modèle KNN selon le nombre de voisins	19
11	Comparaison des performances des modèles	19

Liste des tableaux

1	Variables du jeu de données 50_Startups	5
2	Statistiques descriptives des variables numériques	6
3	Corrélations entre les variables explicatives numériques et le profit	7
4	Performances de la régression linéaire multiple	8
5	Comparaison des performances des modèles	10

Introduction générale

L'apprentissage statistique occupe une place importante dans l'analyse moderne des données. Il regroupe des méthodes permettant d'exploiter des observations afin d'expliquer un phénomène ou de prédire une variable d'intérêt. Dans le cadre de l'apprentissage supervisé, les données sont associées à une variable cible connue, ce qui permet d'entraîner un modèle et d'évaluer sa capacité à généraliser sur de nouvelles observations [3, 2].

Parmi ces méthodes, la régression linéaire constitue un modèle fondamental. Elle permet d'étudier la relation entre une variable quantitative à expliquer et une ou plusieurs variables explicatives. Sa simplicité, son interprétabilité et ses fondements mathématiques en font un outil adapté à une étude en Licence Mathématiques, parcours Statistique et Applications.

Ce stage de fin d'année, réalisé à l'Université de Poitiers au sein de l'UFR Sciences Fondamentales et Appliquées, porte sur le sujet suivant : *Apprentissage statistique : théorie et applications pour le modèle de régression linéaire*. Ce thème s'inscrit dans la continuité de ma formation, car il mobilise des notions de statistique, de probabilités, d'algèbre linéaire, de programmation et d'analyse de données. Il est aussi lié à mon projet professionnel, orienté vers l'analyse statistique et la modélisation prédictive. Le choix de l'UFR SFA s'explique par son cadre universitaire directement lié à ma formation.

L'application pratique porte sur la prédiction du profit de startups. Le jeu de données étudié contient des variables explicatives telles que les dépenses en recherche et développement, les dépenses administratives, les dépenses marketing et l'État géographique de la startup. La variable cible est le profit. L'objectif est donc de construire un modèle capable d'estimer ce profit à partir des informations disponibles.

Ce travail vise à présenter les bases théoriques de la régression linéaire, notamment sa formulation, l'estimation par les moindres carrés et les critères d'évaluation, puis à appliquer ces notions avec Python dans un environnement Jupyter Notebook. La régression linéaire multiple constitue le modèle principal, tandis que le KNN Regressor sert de méthode comparative.

Le rapport présente le cadre du stage, les notions théoriques, la préparation des données, puis les résultats et limites de l'étude.

Présentation de la structure d'accueil

Le stage de fin d'année a été réalisé au sein de l'Université de Poitiers, dans le cadre de la Licence Mathématiques, parcours Statistique et Applications. L'Université de Poitiers est un établissement d'enseignement supérieur et de recherche proposant des formations dans plusieurs domaines, notamment les sciences, les lettres, le droit, l'économie, la santé et les sciences humaines.

La structure d'accueil de ce stage est l'UFR Sciences Fondamentales et Appliquées, appelée UFR SFA. Cette composante regroupe plusieurs formations scientifiques, notamment en mathématiques, informatique, physique, chimie et sciences appliquées. Elle joue un rôle important dans la formation des étudiants en leur permettant d'acquérir des connaissances théoriques solides ainsi que des compétences pratiques.

Dans le cadre de la Licence Mathématiques, parcours Statistique et Applications, l'UFR SFA propose une formation progressive en analyse, algèbre, probabilités, statistique, modélisation et programmation. Ce cadre est donc directement lié au sujet du stage, qui porte sur l'apprentissage statistique et le modèle de régression linéaire.

Le choix de cette structure d'accueil est cohérent avec le contenu de la formation suivie. Le stage permet de relier les notions abordées en cours à une application concrète d'analyse de données. Il constitue également une occasion d'approfondir l'utilisation d'outils informatiques comme Python et Jupyter Notebook pour mettre en œuvre des méthodes statistiques.

Développement

1 Cadre théorique

L'apprentissage statistique regroupe des méthodes permettant de construire un modèle à partir de données observées afin d'expliquer un phénomène ou de prédire une variable d'intérêt. Dans le cadre de l'apprentissage supervisé, chaque observation est décrite par des variables explicatives et associée à une variable cible connue. Lorsque cette variable cible est quantitative, on parle d'un problème de régression.

Dans ce travail, le modèle principal étudié est la régression linéaire multiple. Elle permet d'expliquer une variable quantitative Y à partir de plusieurs variables explicatives $X_1, X_2, \dots, X_p$. Pour une observation i , le modèle s'écrit :

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + \varepsilon_i$$

où β_0 représente la constante, $\beta_1, \dots, \beta_p$ les coefficients du modèle et ε_i le terme d'erreur. Sous forme matricielle, le modèle s'écrit :

$$Y = X\beta + \varepsilon$$

L'estimation des coefficients repose sur la méthode des moindres carrés, qui cherche à minimiser la somme des carrés des erreurs entre les valeurs observées et les valeurs prédites :

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Lorsque la matrice $X^T X$ est inversible, l'estimateur des moindres carrés est donné par :

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

L'un des avantages principaux de la régression linéaire est son interprétabilité. Chaque coefficient mesure l'association moyenne entre une variable explicative et la variable cible, toutes choses égales par ailleurs. Il faut toutefois rappeler qu'une association statistique ne permet pas, à elle seule, d'établir une relation causale.

2 Hypothèses et évaluation du modèle linéaire

L'utilisation d'un modèle de régression linéaire repose sur plusieurs hypothèses importantes. La première est l'hypothèse de linéarité : la relation entre les variables explicatives et la variable cible doit pouvoir être approximée par une combinaison linéaire. Dans cette étude, cette hypothèse semble raisonnable, car l'analyse exploratoire montre une relation croissante nette entre les dépenses en recherche et développement et le profit.

Une deuxième hypothèse concerne l'indépendance des erreurs. Les erreurs de prédiction doivent être indépendantes les unes des autres. Dans le cadre du jeu de données étudié, chaque observation correspond à une startup différente, ce qui rend cette hypothèse acceptable. Il faut cependant rester prudent, car le dataset ne fournit pas d'informations détaillées sur les relations éventuelles entre les entreprises.

Une autre hypothèse importante est l'homoscédasticité, c'est-à-dire la constance de la variance des erreurs. En pratique, cette hypothèse peut être étudiée à l'aide d'un graphique représentant les résidus en fonction des valeurs prédites. Si les résidus sont répartis de manière aléatoire autour de zéro, sans forme particulière, cela suggère que le modèle est relativement adapté.

Enfin, la régression linéaire suppose l'absence de multicollinéarité forte entre les variables explicatives. Lorsque deux variables explicatives sont très corrélées entre elles, l'estimation des coefficients peut devenir instable. Pour cette raison, l'analyse de la matrice de corrélation constitue une étape importante avant la modélisation.

L'évaluation du modèle repose sur plusieurs métriques complémentaires. Le MSE mesure la moyenne des carrés des erreurs, mais il est sensible aux grandes erreurs. Le RMSE, racine carrée du MSE, présente l'avantage d'être exprimé dans la même unité que la variable cible. Le MAE mesure l'erreur absolue moyenne et est moins sensible aux valeurs extrêmes. Enfin, le coefficient de détermination R^2 mesure la proportion de variabilité de la variable cible expliquée par le modèle.

Ces métriques ne doivent pas être interprétées séparément. Un bon modèle doit présenter des erreurs faibles, mais aussi un coefficient R^2 élevé. Dans cette étude, elles permettent de comparer la régression linéaire multiple avec le modèle KNN Regressor.

3 Présentation et préparation du jeu de données

L'application pratique repose sur le jeu de données `50_Startups`. Il contient 50 observations correspondant à 50 startups. L'objectif est de prédire le profit réalisé par une startup à partir de plusieurs variables explicatives.

Variable	Type	Description
R&D Spend	Quantitative	Dépenses en recherche et développement
Administration	Quantitative	Dépenses administratives
Marketing Spend	Quantitative	Dépenses marketing
State	Qualitative	État géographique de la startup
Profit	Quantitative	Profit réalisé par la startup

TABLE 1 – Variables du jeu de données `50_Startups`

La variable cible est `Profit`. Les autres variables sont utilisées comme variables explicatives. Comme la variable cible est quantitative continue, il s'agit d'un problème de régression supervisée.

Une première étape de préparation a consisté à vérifier la structure du dataset, les types de variables et la présence éventuelle de valeurs manquantes. Le jeu de données contient 50 lignes et 5 colonnes. Aucune valeur manquante n’a été détectée, ce qui simplifie la préparation des données.

La variable **State** est qualitative. Elle ne peut donc pas être utilisée directement par les modèles numériques. Elle a été transformée à l’aide d’un encodage one-hot, qui consiste à créer des variables binaires correspondant aux différentes modalités de l’État. Une modalité peut être supprimée afin d’éviter une redondance parfaite entre les variables indicatrices.

Les données ont ensuite été séparées en deux ensembles : un ensemble d’apprentissage représentant 80 % des observations et un ensemble de test représentant 20 %. L’ensemble d’apprentissage sert à entraîner les modèles, tandis que l’ensemble de test permet d’évaluer leur capacité de généralisation.

Pour le modèle KNN Regressor, une étape supplémentaire de standardisation a été nécessaire. En effet, ce modèle repose sur le calcul de distances entre observations. Si les variables ne sont pas exprimées sur la même échelle, une variable ayant de grandes valeurs numériques peut dominer artificiellement le calcul des distances. La standardisation permet donc de rendre les variables comparables.

4 Exploration des données

L’analyse exploratoire permet de mieux comprendre la structure du jeu de données avant la phase de modélisation. Les statistiques descriptives montrent que les variables financières ne sont pas toutes sur la même échelle. Les dépenses marketing peuvent atteindre des montants élevés, tandis que certaines startups présentent des dépenses nulles en recherche et développement ou en marketing.

Variable	Moyenne	Écart-type	Min	Max
R&D Spend	73 721.62	45 902.26	0.00	165 349.20
Administration	121 344.64	28 017.80	51 283.14	182 645.56
Marketing Spend	211 025.10	122 290.31	0.00	471 784.10
Profit	112 012.64	40 306.18	14 681.40	192 261.83

TABLE 2 – Statistiques descriptives des variables numériques

Ces statistiques montrent une forte dispersion des montants financiers. La variable **Profit** varie fortement selon les startups, ce qui confirme l’intérêt de construire un modèle capable d’expliquer ces différences. La variable **R&D Spend** présente également une forte variabilité, ce qui suggère que les startups étudiées n’ont pas toutes le même niveau d’investissement en recherche et développement.

L’étude graphique des variables montre une relation croissante nette entre les dépenses

en recherche et développement et le profit. Les startups qui investissent davantage en recherche et développement tendent généralement à obtenir un profit plus élevé. Cette observation suggère que **R&D Spend** constitue une variable importante pour expliquer le profit des startups.

Il convient toutefois de ne pas interpréter cette relation comme une causalité certaine. Le graphique met en évidence une association statistique entre les deux variables, mais il ne permet pas d'affirmer que l'augmentation des dépenses en recherche et développement provoque directement une augmentation du profit.

La matrice de corrélation confirme cette observation. La variable **R&D Spend** présente la corrélation la plus forte avec **Profit**, suivie par **Marketing Spend**. En revanche, la variable **Administration** semble moins liée à la variable cible.




FIGURE 1 – Matrice de corrélation des variables numériques

Variable explicative	Corrélation avec Profit
R&D Spend	0.973
Marketing Spend	0.748
Administration	0.201

TABLE 3 – Corrélations entre les variables explicatives numériques et le profit

Ces résultats justifient l'utilisation d'un modèle de régression linéaire, car certaines relations observées semblent approximativement linéaires, en particulier la relation entre **R&D Spend** et **Profit**.

5 Modélisation par régression linéaire

La régression linéaire multiple constitue le modèle principal de l'étude. Elle est entraînée sur l'ensemble d'apprentissage, puis évaluée sur l'ensemble de test. Le modèle utilise les variables financières ainsi que les variables issues de l'encodage de **State**.

Après entraînement, les valeurs prédites sont comparées aux valeurs réelles de l'ensemble de test. Les performances sont évaluées à l'aide de plusieurs métriques : le MSE, le RMSE, le MAE et le coefficient de détermination R^2 .

Métrique	Valeur
MSE	83 502 864.03
RMSE	9 137.99
MAE	7 514.29
R^2	0.9347

TABLE 4 – Performances de la régression linéaire multiple

Le coefficient R^2 obtenu est égal à 0.9347. Cela signifie que le modèle explique environ 93.47 % de la variabilité du profit sur l'ensemble de test. Le RMSE, égal à environ 9 137.99, représente l'ordre de grandeur moyen de l'erreur de prédiction dans l'unité de la variable cible. Le MAE, égal à 7 514.29, indique que l'écart absolu moyen entre les profits réels et les profits prédits est d'environ 7 514 unités.

Ces résultats montrent que la régression linéaire multiple fournit une bonne qualité de prédiction dans le cadre de cette étude. Ils sont cohérents avec l'analyse exploratoire, qui avait mis en évidence une forte relation linéaire entre les dépenses en recherche et développement et le profit.




FIGURE 2 – Comparaison entre les profits réels et les profits prédits

La comparaison entre les valeurs réelles et les valeurs prédites permet d'observer concrètement la qualité du modèle. Lorsque les points sont proches de la droite de référence, cela signifie que les prédictions sont proches des valeurs observées. Dans cette

étude, les prédictions sont globalement satisfaisantes, même si certains écarts restent présents. Ces écarts sont normaux dans un problème réel de prédiction, car le modèle ne peut pas expliquer toutes les variations individuelles du profit.

6 Analyse des résidus

L'analyse des résidus permet d'évaluer plus finement la qualité du modèle linéaire. Pour chaque observation de l'ensemble de test, le résidu correspond à la différence entre la valeur réelle du profit et la valeur prédite par le modèle :

$$e_i = y_i - \hat{y}_i$$

Un modèle bien ajusté doit produire des résidus globalement centrés autour de zéro. Si les résidus présentent une structure particulière, cela peut indiquer que le modèle linéaire ne capture pas correctement la relation entre les variables explicatives et la variable cible.

L'analyse des résidus permet aussi de vérifier, de manière visuelle, si les erreurs du modèle semblent réparties de manière équilibrée. Lorsque les résidus sont dispersés autour de zéro sans forme particulière, cela suggère que le modèle ne présente pas de biais évident. En revanche, si les résidus suivent une forme courbe ou présentent une dispersion croissante, cela peut indiquer une relation non linéaire ou une hétéroscédasticité.

Dans cette étude, les résidus restent globalement compatibles avec l'utilisation d'un modèle linéaire. Certains écarts sont observables, mais ils ne remettent pas en cause la tendance générale. Ces erreurs peuvent s'expliquer par la petite taille du dataset et par l'absence de certaines variables potentiellement importantes, comme le secteur d'activité, l'ancienneté de l'entreprise, le nombre d'employés ou le contexte économique.

L'interprétation des coefficients du modèle doit également être faite avec prudence. Un coefficient positif associé à une variable indique qu'une augmentation de cette variable est associée à une augmentation du profit prédit, toutes choses égales par ailleurs. Il ne s'agit pas nécessairement d'une relation causale.

7 Comparaison avec le modèle KNN Regressor

Le modèle KNN Regressor est utilisé comme méthode comparative. Contrairement à la régression linéaire, il ne suppose pas de relation linéaire entre les variables explicatives et la variable cible. Il prédit la valeur d'une nouvelle observation à partir des K observations les plus proches dans l'ensemble d'apprentissage.

Comme le KNN repose sur des distances, les variables doivent être standardisées avant l'entraînement. Cette étape permet d'éviter qu'une variable mesurée sur une grande échelle domine artificiellement le calcul des distances.

Dans cette étude, une première expérimentation a été réalisée avec $K = 1$. Les résultats obtenus sont les suivants :

Modèle	MSE	RMSE	MAE	R^2
Régression linéaire multiple	83 502 864.03	9 137.99	7 514.29	0.9347
KNN Regressor ($K = 1$)	794 476 470.55	28 186.46	21 053.96	0.3788

TABLE 5 – Comparaison des performances des modèles

La régression linéaire multiple obtient des performances nettement supérieures au KNN. Son coefficient R^2 est beaucoup plus élevé et ses erreurs de prédiction sont plus faibles. Le KNN obtient un R^2 de 0.3788, ce qui indique une capacité explicative limitée dans ce cas.

Le choix du nombre de voisins K influence fortement les performances du modèle KNN. Lorsque $K = 1$, le modèle utilise uniquement l’observation la plus proche pour effectuer la prédiction. Cette approche peut être très sensible aux observations particulières et conduire à une forte variabilité des prédictions. À l’inverse, lorsque K est trop grand, le modèle moyenne un nombre important d’observations, ce qui peut lisser excessivement les résultats.

Dans le notebook, plusieurs valeurs de K ont été testées afin d’étudier l’évolution du RMSE. Cette démarche permet d’observer si un autre choix de K améliore les performances du modèle.

Même après l’étude de différentes valeurs de K , le KNN reste moins adapté que la régression linéaire multiple dans le cadre de cette étude. Cette différence peut s’expliquer par plusieurs facteurs. D’abord, le jeu de données contient seulement 50 observations, ce qui limite l’efficacité d’une méthode fondée sur la proximité entre observations. Ensuite, l’analyse exploratoire a montré une relation fortement linéaire entre certaines variables, notamment **R&D Spend**, et le profit. Dans ce contexte, un modèle linéaire simple et interprétable est plus adapté.

8 Discussion, limites et perspectives

Les résultats obtenus montrent que la régression linéaire multiple est le modèle le plus adapté dans le cadre de cette étude. Le coefficient R^2 obtenu sur l’ensemble de test est égal à 0.9347, ce qui indique que le modèle explique une grande partie de la variabilité du profit. Les erreurs RMSE et MAE restent relativement faibles par rapport à l’amplitude de la variable cible.

La variable **R&D Spend** joue un rôle central dans la prédiction du profit. Cette conclusion est cohérente avec l’analyse exploratoire, puisque cette variable présente la plus forte corrélation avec la variable cible. La variable **Marketing Spend** apporte également une information utile, même si son lien avec le profit est moins marqué. En revanche, la variable

Administration semble moins influente dans cette étude.

La comparaison avec le modèle KNN Regressor confirme l'intérêt de la régression linéaire pour ce dataset. Le KNN obtient un coefficient R^2 nettement plus faible et des erreurs de prédiction plus élevées. Ce résultat montre qu'un modèle plus flexible n'est pas nécessairement meilleur. Le choix d'un modèle doit dépendre de la structure des données, de la taille du dataset et de l'objectif de l'étude.

Malgré les bons résultats obtenus, plusieurs limites doivent être soulignées. La première limite concerne la taille du jeu de données. Avec seulement 50 observations, les résultats peuvent être sensibles au découpage entre l'ensemble d'apprentissage et l'ensemble de test. Une seule séparation des données ne suffit donc pas toujours à garantir une évaluation robuste des performances.

Une deuxième limite concerne le nombre réduit de variables explicatives. Le profit d'une startup peut dépendre de nombreux autres facteurs non présents dans le dataset, comme le secteur d'activité, l'ancienneté de l'entreprise, le nombre d'employés, la stratégie commerciale, la concurrence ou encore le contexte économique. L'absence de ces variables limite la portée de l'interprétation.

Une troisième limite concerne l'interprétation des coefficients. La régression linéaire met en évidence des associations statistiques entre les variables, mais elle ne permet pas d'établir une causalité. Par exemple, même si les dépenses en recherche et développement sont fortement associées au profit, cela ne prouve pas à lui seul qu'une augmentation de ces dépenses provoque directement une augmentation du profit.

Pour améliorer ce travail, il serait pertinent d'utiliser un jeu de données plus large et plus riche. Une validation croisée pourrait aussi être mise en place afin d'obtenir une estimation plus stable des performances. Enfin, d'autres modèles pourraient être testés, comme les arbres de décision, les forêts aléatoires ou les méthodes de boosting, afin d'étudier si des modèles non linéaires peuvent améliorer les prédictions dans un cadre plus général.

Ainsi, cette étude montre que la régression linéaire multiple constitue un modèle pertinent pour prédire le profit des startups dans le dataset étudié. Elle présente l'avantage d'être à la fois performante, simple et interprétable, ce qui correspond bien à l'objectif du stage.

Conclusion générale

Ce stage de fin d'année avait pour objectif d'étudier le modèle de régression linéaire dans le cadre de l'apprentissage statistique, puis de l'appliquer à un problème concret de prédiction du profit de startups. Ce travail a permis de relier les notions théoriques étudiées en Licence Mathématiques, parcours Statistique et Applications, à une démarche pratique d'analyse de données.

Dans un premier temps, les fondements de l'apprentissage supervisé et du modèle de régression linéaire ont été présentés. L'étude a notamment mis en évidence le rôle de la méthode des moindres carrés, des coefficients du modèle et des critères d'évaluation tels que le MSE, le RMSE, le MAE et le coefficient R^2 .

Dans un second temps, le jeu de données **50_Startups** a été préparé et exploré. L'analyse descriptive et la matrice de corrélation ont montré que la variable **R&D Spend** était fortement liée au profit.

Enfin, la modélisation a permis de comparer la régression linéaire multiple au modèle KNN Regressor. Les résultats obtenus montrent que la régression linéaire fournit de meilleures performances, avec un coefficient R^2 élevé sur l'ensemble de test. Ce modèle apparaît donc comme une méthode simple, efficace et interprétable pour ce problème.

Ce travail présente toutefois certaines limites, notamment la petite taille du jeu de données. Il pourrait être prolongé par l'utilisation d'un dataset plus large, d'une validation croisée et d'autres modèles prédictifs.

Bibliographie

- [1] Aurélien Géron. *Hands-On Machine Learning with Scikit-Learn, Keras, and Tensor-Flow*. O'Reilly Media, Sebastopol, 2 edition, 2019.
- [2] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning : Data Mining, Inference, and Prediction*. Springer, New York, 2 edition, 2009.
- [3] Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. *An Introduction to Statistical Learning : With Applications in R*. Springer, New York, 2013.
- [4] Michael H. Kutner, Christopher J. Nachtsheim, John Neter, and William Li. *Applied Linear Statistical Models*. McGraw-Hill, New York, 5 edition, 2005.
- [5] Matplotlib development team. *Matplotlib Documentation*. Matplotlib, 2026. URL <https://matplotlib.org/stable/contents.html>. Documentation officielle consultée en 2026.
- [6] Douglas C. Montgomery, Elizabeth A. Peck, and G. Geoffrey Vining. *Introduction to Linear Regression Analysis*. Wiley, Hoboken, 5 edition, 2012.
- [7] Pandas development team. *Pandas Documentation*. Pandas, 2026. URL <https://pandas.pydata.org/docs/>. Documentation officielle consultée en 2026.
- [8] Scikit-learn developers. *Scikit-learn : Machine Learning in Python*. Scikit-learn, 2026. URL <https://scikit-learn.org/stable/>. Documentation officielle consultée en 2026.
- [9] Michael Waskom. *Seaborn : Statistical Data Visualization*. Seaborn, 2026. URL <https://seaborn.pydata.org/>. Documentation officielle consultée en 2026.

Annexes

Les annexes regroupent des éléments complémentaires au rapport principal. Elles permettent de présenter des extraits de code, des résultats détaillés et des figures supplémentaires sans alourdir le développement.

Annexe A : Extraits du code Python

Cette annexe présente les principales étapes du notebook Jupyter utilisé pour l'étude : chargement des données, préparation, séparation apprentissage-test, modélisation et évaluation.

Chargement des bibliothèques

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.neighbors import KNeighborsRegressor
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
```

Séparation des données

```
X = dataset.drop("Profit", axis=1)
y = dataset["Profit"]

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=0
)
```

Modèle de régression linéaire

```
regressor = LinearRegression()
regressor.fit(X_train, y_train)

y_pred = regressor.predict(X_test)
```

Évaluation du modèle

```
mse = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)
mae = mean_absolute_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print("MSE :", mse)
print("RMSE :", rmse)
print("MAE :", mae)
print("R2 :", r2)
```

Annexe B : Résultats détaillés du modèle KNN

Le modèle KNN Regressor a été utilisé comme méthode comparative. Comme il repose sur le calcul de distances, les variables ont été standardisées avant l'entraînement.

```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()

X_train_sc = scaler.fit_transform(X_train)
X_test_sc = scaler.transform(X_test)

reg = KNeighborsRegressor(n_neighbors=1)
reg.fit(X_train_sc, y_train)

y_pred_knn = reg.predict(X_test_sc)
```

Pour étudier l'influence du nombre de voisins, plusieurs valeurs de K ont été testées.

```
rmse_val = []

for K in range(20):
```

```

K = K + 1
model = KNeighborsRegressor(n_neighbors=K)

model.fit(X_train_sc, y_train)
pred = model.predict(X_test_sc)

error = np.sqrt(mean_squared_error(y_test, pred))
rmse_val.append(error)

rsquared = r2_score(y_test, pred)

print("RMSE value for k=", K, "is:", error)
print("R2 value for k=", K, "is:", rsquared)

```

Annexe C : Figures complémentaires

Les figures suivantes complètent l'analyse exploratoire et les résultats de modélisation présentés dans le développement principal du rapport.




FIGURE 3 – Distribution des dépenses en recherche et développement




FIGURE 4 – Distribution des dépenses administratives




FIGURE 5 – Distribution des dépenses marketing




FIGURE 6 – Distribution du profit




FIGURE 7 – Boxplots des principales variables numériques




FIGURE 8 – Relations entre les variables numériques du jeu de données




FIGURE 9 – Boxplot de la variable Profit




FIGURE 10 – Évolution de la RMSE du modèle KNN selon le nombre de voisins




FIGURE 11 – Comparaison des performances des modèles